


---

# Machine Learning (Basics) with numpy

---



Βασίλης Ρουσόπουλος

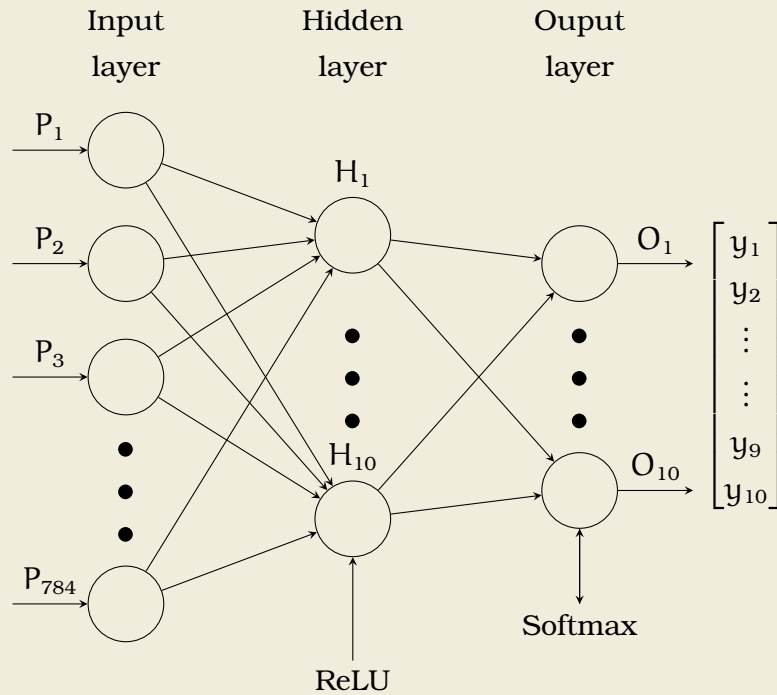
(Documentation του σχετικού προγράμματος αναγνώρισης χειρόγραφων αριθμών)

# Contents

<b>Δομή Νευρωνικού Δικτύου</b>	<b>1</b>
<b>Input</b>	<b>2</b>
<b>ReLU, Softmax (συναρτήσεις ενεργοποίησης)</b>	<b>3</b>
<b>Mean squared error</b>	<b>4</b>
<b>Forward Propagation</b>	<b>5</b>
<b>Backward Propagation</b>	<b>6</b>
<b>Gradient Descent</b>	<b>10</b>

## Δομή Νευρωνικού Δικτύου

Το νευρωνικό μας δίκτυο θα έχει τρία layers. Το πρώτο που θα είναι το input layer, ένα hidden layer και ένα output layer.



Με  $P_i \in \{1, 2, \dots, 255\}$ ,  $i = \{1, 2, \dots, 784\}$  να είναι η τιμή του  $i$ -οστού pixel,  $H_i$ ,  $i = \{1, 2, \dots, 10\}$  να είναι η τιμή του  $i$ -οστού νευρώνα στο hidden layer,  $O_i$ ,  $i = \{1, 2, \dots, 10\}$  να είναι η τιμή του  $i$ -οστού νευρώνα στο outer layer πριν την εφαρμογή της softmax και τέλος  $y_1, y_2, \dots, y_{10}$  να αποτελούν συνάρτηση πιθανότητας διακριτής κατανομής, δηλαδή  $\sum_{i=1}^{10} y_i = 1$  και  $y_i, i = \{1, 2, \dots, 10\}$ , και το κάθε  $y_i$  αντιστοιχεί στο  $(i - 1)$ -αριθμό,  $y_1 \rightarrow 0, y_2 \rightarrow 1, \dots, y_{10} \rightarrow 9$  με  $y_i$  η πιθανότητα το input να είναι το  $(i - 1)$ -οστό νούμερο.

## Input

Το input αποτελείται απο εικόνες διάστασης  $28 \times 28$  pixels (784 pixels στο σύνολο). Κάθε εικόνα μετατρέπεται σε ένα διάνυσμα διάστασης  $784 \times 1$ . Επειδή οι τιμές κάθε pixels κυμαίνονται απο το 0 μέχρι το 255, διαιρούμε κάθε τιμή του διανύσματος με 255 και κανονικοποιούμε κάθε τιμή στο διάστημα  $[0, 1]$

Επιπλέον αρχικοποιούμε τέσσερεις πίνακες έστω  $W_1 \in \mathbb{M}^{784 \times 10}(\mathbb{R})$ ,  $b_1 \in \mathbb{M}^{10 \times 1}(\mathbb{R})$ ,  $W_2 \in \mathbb{M}^{10 \times 10}(\mathbb{R})$ ,  $b_2 \in \mathbb{M}^{10 \times 1}(\mathbb{R})$  με  $W_1$  να είναι τα βάρη που ενώνουν τις ακμές του input layer με το πρώτο,  $b_1$  να είναι τα biases του πρώτου layer,  $W_2$  τα βάρη που ενώνουν τις ακμές του πρώτου layer με το output layer και τέλος  $b_2$  τα biases του output layer.

## ReLU, Softmax (συναρτήσεις ενεργοποίησης)

**Ορισμός (ReLU):** Η συνάρτηση ReLU ορίζεται ως  $\varphi : \mathbb{R} \rightarrow [0, \infty)$

$$\varphi(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Η ReLU (και γενικότερα οι συναρτήσεις ενεργοποίησης) εισάγουν μη γραμμικότητα στο νευρωνικό μας δίκτυο. Ο υπολογισμός της τιμής ενός νευρώνα  $a$ , στο layer  $l$ , δίνεται ως ο γραμμικός συνδυασμός  $a^{(l)} = W a^{(l-1)} + b$ . Επομένως χωρίς συνάρτηση ενεργοποίησης δεν θα είχε νόημα ο αριθμός των hidden layers και η γενικότερη πολυπλοκότητα του νευρωνικού δικτύου καθώς το output θα ήταν πάλι μια γραμμική συνάρτηση.

**Ορισμός (Softmax):** Η συνάρτηση Softmax,  $\sigma : \mathbb{R}^n \rightarrow (0, 1)^n$ ,  $n > 1$  για διάνυσμα  $\mathbf{v} = (v_1, \dots, v_n) \in \mathbb{R}^n$  ορίζεται ως

$$\sigma(\mathbf{v}) = (\sigma(v_1), \dots, \sigma(v_n))$$

$$\text{με } \sigma(v_i) = \frac{e^{v_i}}{\sum_{i=1}^n e^{v_i}}$$

Η Softmax μετατρέπει το διάνυσμα  $\mathbf{v}$  σε συνάρτηση πιθανότητας διακριτής κατανομής με  $n$  ενδεχόμενα.

## Mean squared error

Για τον υπολογισμό της απόκλισης του αποτελέσματος τους output layer απο το αναμενόμενο, έστω  $\mu$ , θεωρούμε διάνυσμα  $\mathbf{y} \in \mathbb{M}^{(n+1) \times 1}(\mathbb{R})$

$$\mathbf{y} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ \vdots \\ y_n \end{bmatrix} \quad \text{με} \quad \begin{cases} y_i = \mu, & \text{αν } i = \mu \\ 0, & \text{διαφορετικά} \end{cases}$$

Έπειτα παίρνουμε το άθροισμα των τετραγώνων των διαφορών των τιμών του output με το  $\mathbf{y}$ .

Αρα το loss του συστήματος, εξαρτάται απο το διάνυσμα που μας δίνει το output layer έπειτα απο την εφαρμογή της softmax αλλα και το  $\mathbf{b}$ , δηλαδή

$$\mathcal{L} = \sum_{i=1}^{10} (a_i^{[L]} - y_i)^2$$

## Forward Propagation

Όπως αναφέραμε και πιο πάνω, ο υπολογισμός της τιμής ενός νευρώνα  $a_i$  στο layer  $l$ , δίνεται ως ο γραμμικός συνδυασμός

$$a_i^{(l)} = w_{i,j} \cdot a_j^{(l-1)} + b_i \quad (1)$$

, με  $a_j^{(l-1)}$  ο  $j$ -νευρώνας στο layer  $l-1$ ,  $w_{i,j}$  το βάρος της ακμής που συνδέει το  $i$ -νευρώνα με τον  $j$ -νευρώνα και  $b_i$  το bias του  $i$ -νευρώνα. Επομένως αν θέλουμε να εκφράσουμε όλους του νευρώνες με την βοήθεια πινάκων θα έχουμε:

Για τις τιμές των νευρώνων στο hidden layer θα δείξουμε ότι ισχύει η ακόλουθη ισότητα

$$\mathbf{a}^{(1)} = W_1^T \mathbf{a}^{(1-1)} + \mathbf{b}_1 \quad (2)$$

με  $W_1^T$  να είναι ο transpose πίνακας των βαρών μεταξύ input layer και hidden layer.

$$\begin{aligned} \mathbf{a}^{(1)} &= W_1^T \mathbf{a}^{(1-1)} + \mathbf{b}_1 \\ \Rightarrow \mathbf{a}^{(1)} &= \begin{bmatrix} w_{1,1} & w_{2,1} & \dots & w_{784,1} \\ w_{1,2} & w_{2,2} & \dots & w_{784,2} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1,10} & w_{2,10} & \dots & w_{784,10} \end{bmatrix} \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_{784} \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_{10} \end{bmatrix} \\ \Rightarrow \mathbf{a}^{(1)} &= \begin{bmatrix} \sum_{i=1}^{784} w_{i,1} p_i + b_1 \\ \sum_{i=1}^{784} w_{i,2} p_i + b_2 \\ \vdots \\ \sum_{i=1}^{784} w_{i,10} p_i + b_{10} \end{bmatrix}, \quad \text{που είναι ακριβώς η εξίσωση (1), και άρα} \\ \Rightarrow \mathbf{a}^{(1)} &= \begin{bmatrix} a_1^{(1)} \\ a_2^{(1)} \\ \vdots \\ a_{10}^{(1)} \end{bmatrix} \end{aligned}$$

## Backward Propagation

Ο στόχος μας είναι να ελαχιστοποιήσουμε το loss του νευρωνικού δικτύου. Για να το πετύχουμε αυτό θα πρέπει αν βρούμε τα ελάχιστα της συνάρτησης του loss  $\mathcal{L} = \sum_{i=1}^{10} (a_i^{(l)} - y_i)^2$ . Για να βρούμε το ελάχιστο της ξεκινώντας από ένα τυχαίο σημείο της, θα πρέπει να κινηθούμε προς την κατεύθυνση κατά την οποία η συνάρτηση μειώνεται γρηγορότερα. Όμως από θεωρία γνωρίζουμε ότι μια συνάρτηση  $f$  αυξάνεται γρηγορότερα κατά την κατά την κατεύθυνση του διανύσματος  $\vec{\nabla} f$  και επομένως θα πρέπει να κινηθούμε στην κατεύθυνση του διανύσματος  $-\vec{\nabla} f$ .

Άρα για την συνάρτηση  $\mathcal{L}$  αρκεί να βρούμε την παράγωγό της προς όλα τα βάρη και biases δηλαδή για τα βάρη στο  $l$ -layer

$$\frac{\partial \mathcal{L}}{\partial w_i^{(l)}} \text{ και } \frac{\partial \mathcal{L}}{\partial b_j^{(l)}}, \forall i, \forall j$$

Επομένως μέχρι τώρα έχουμε

$$z_i^{(l)} = w_{i,j}^{(l)} \cdot a_j^{(l-1)} + b_i^{(l)}$$

η τιμή του νευρώνα  $i$  πριν εφαρμόσουμε την συνάρτηση ενεργοποίησης.

Έστω  $\sigma$  η συνάρτηση ενεργοποίησης και  $a_i$  η τιμή του νευρώνα μετά την εφαρμογή της  $\sigma$ , δηλαδή

$$a_i^{(l)} = \sigma(z_i^{(l)})$$

Άρα από τον κανόνα της αλυσίδας έχουμε για τα βάρη που συνδέουν το hidden με το output layer

$$\frac{\partial \mathcal{L}}{\partial w_i^{(l)}} = \frac{\partial \mathcal{L}}{\partial a_i^{(l)}} \cdot \frac{\partial a_i^{(l)}}{\partial z_i^{(l)}} \cdot \frac{\partial z_i^{(l)}}{\partial w_{i,j}^{(l)}} \quad (3)$$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(l)}} = 2(a_i^{(l)} - y_i) \cdot \mathbf{1}_{\{z_i^{(l)} > 0\}} \cdot a_j^{(l-1)} \quad (4)$$

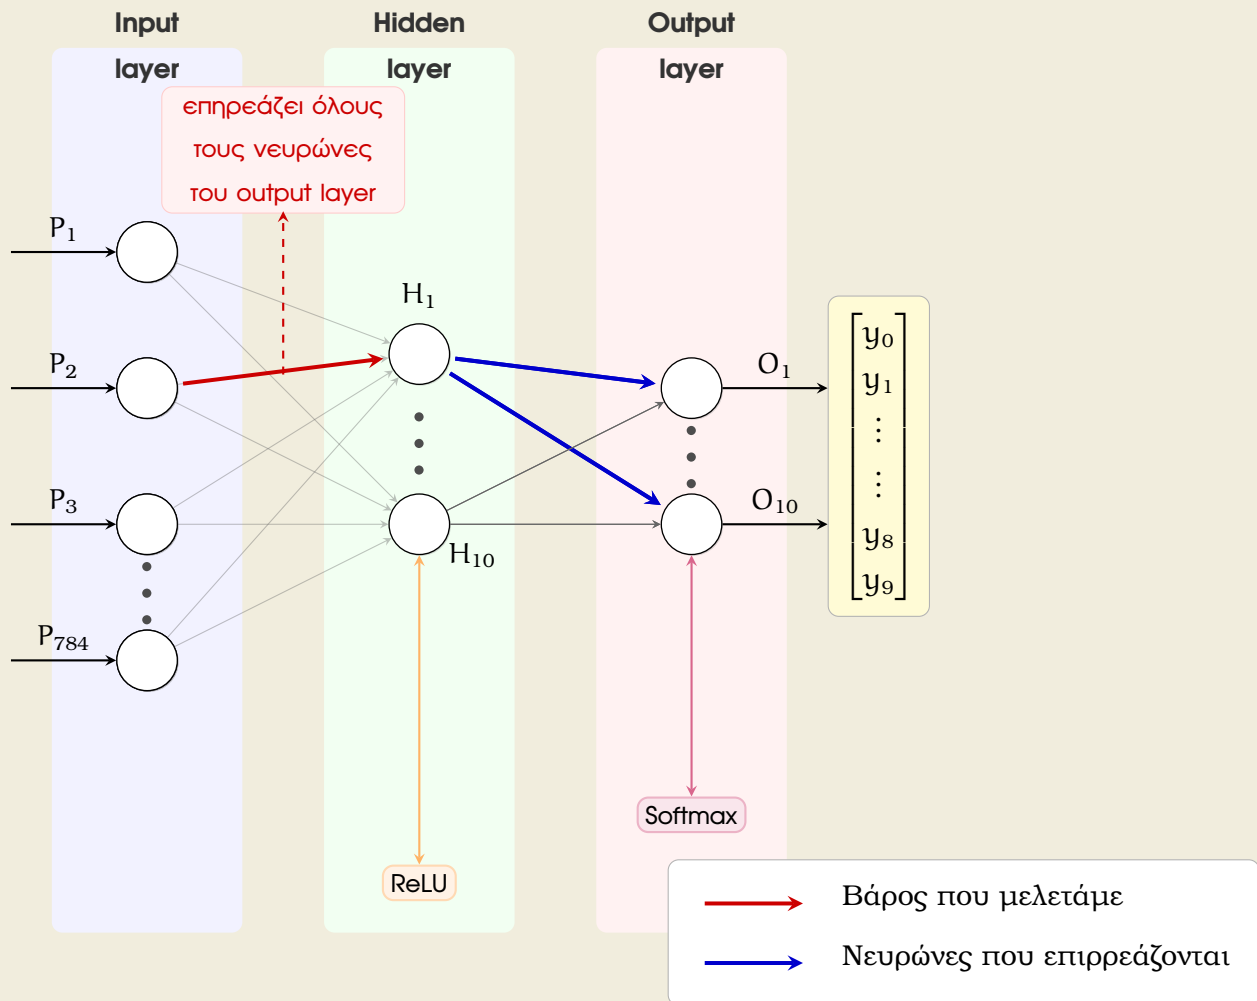
Αντίστοιχα για τα biases

$$\frac{\partial \mathcal{L}}{\partial b_i^{(l)}} = \frac{\partial \mathcal{L}}{\partial a_i^{(l)}} \cdot \frac{\partial a_i^{(l)}}{\partial z_i^{(l)}} \cdot \frac{\partial z_i^{(l)}}{\partial b_i^{(l)}} \quad (5)$$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial b_i^{(l)}} = 2(a_i^{(l)} - y_i) \cdot \mathbf{1}_{\{z_i^{(l)} > 0\}} \cdot 1 \quad (6)$$



Όμως τα πράγματα δυσκολεύουν όταν πάμε να υπολογίσουμε τις ίδες παραγώγους για τα βάρη και τα biases μεταξύ input και hidden layer.



Στην περίπτωση αυτή κάθε βάρος και bias συμβάλει στο διάνυσμα του output layer και επομένως η μερική παράγωγος του loss προς αυτά θα είναι πιο σύνθετη. Συγκεκριμένα για τα βάρη και biases του  $l - 1$  layer θα έχουμε

$$\frac{\partial \mathcal{L}}{\partial w_i^{(l-1)}} = \frac{\partial a_i^{(l-1)}}{\partial z_i^{(l-1)}} \cdot \frac{\partial z_i^{(l-1)}}{\partial w_{i,j}^{(l-1)}} \cdot \frac{\partial \mathcal{L}}{\partial a_i^{(l-1)}} \quad (7)$$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(l-1)}} = \mathbf{1}_{\{z_i^{(l-1)} > 0\}} \cdot a_i^{(l-2)} \cdot \sum_i w_{k,i}^{(l)} \mathbf{1}_{\{z_i^{(l)} > 0\}} 2(a_i^{(l)} - y_i) \quad (8)$$

Αντίστοιχα για τα biases έχουμε

$$\frac{\partial \mathcal{L}}{\partial b_i^{(l-1)}} = \frac{\partial a_i^{(l-1)}}{\partial z_i^{(l-1)}} \cdot \frac{\partial z_i^{(l-1)}}{\partial b_i^{(l-1)}} \cdot \frac{\partial \mathcal{L}}{\partial a_i^{(l-1)}} \quad (9)$$

$$\Rightarrow \frac{\partial \mathcal{L}}{\partial b_i^{(l-1)}} = \mathbf{1}_{\{z_i^{(l-1)} > 0\}} \cdot 1 \cdot \sum_i w_{k,i}^{(l)} \mathbf{1}_{\{z_i^{(l)} > 0\}} 2(a_i^{(l)} - y_i) \quad (10)$$

Επομένως για να υπολογίσουμε τις παραγώγους όλων των βαρών και biases με την βοήθεια πινάκων, θα δείξουμε ότι

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \mathbf{a}^{(1)} [2(\mathbf{a}^{(2)} - \mathbf{y})]^T \\ \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} a_1^{(1)} \\ a_2^{(1)} \\ \vdots \\ a_{10}^{(1)} \end{bmatrix} \begin{bmatrix} 2(a_1^{(2)} - y_1) & 2(a_2^{(2)} - y_2) & \cdots & 2(a_{10}^{(2)} - y_{10}) \end{bmatrix} \\ \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} a_1^{(1)} \cdot 2(a_1^{(2)} - y_1) & a_1^{(1)} \cdot 2(a_2^{(2)} - y_2) & \cdots & a_1^{(1)} \cdot 2(a_{10}^{(2)} - y_{10}) \\ \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & & \vdots \\ a_{10}^{(1)} \cdot 2(a_1^{(2)} - y_1) & a_{10}^{(1)} \cdot 2(a_2^{(2)} - y_2) & \cdots & a_{10}^{(1)} \cdot 2(a_{10}^{(2)} - y_{10}) \end{bmatrix}\end{aligned}$$

Επομένως κάθε στοιχείο του πίνακα είναι της μορφής  $2(a_i^{(1)} - y_i) \cdot a_j^{(1-1)}$ ,  $\forall i, j \in \{1, 2, \dots, 10\}$  και άρα

$$\frac{\partial \mathcal{L}}{\partial w_i^{(2)}} = \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial w_1^{(2)}} \\ \frac{\partial \mathcal{L}}{\partial w_2^{(2)}} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial w_{10}^{(2)}} \end{bmatrix} \quad (\text{χρησιμοποιώντας την (4)})$$

το οποίο είναι τετριμμένο.

Επίσης θα δείξουμε ότι

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial b_i^{(2)}} &= 2(\mathbf{a}^{(2)} - \mathbf{y}) \\ \Rightarrow \frac{\partial \mathcal{L}}{\partial b_i^{(2)}} &= \begin{bmatrix} 2(a_1^{(2)} - y_1) \\ 2(a_2^{(2)} - y_2) \\ \vdots \\ 2(a_{10}^{(2)} - y_{10}) \end{bmatrix} \\ \Rightarrow \frac{\partial \mathcal{L}}{\partial b_i^{(2)}} &= \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial b_1^{(2)}} \\ \frac{\partial \mathcal{L}}{\partial b_2^{(2)}} \\ \vdots \\ \frac{\partial \mathcal{L}}{\partial b_{10}^{(2)}} \end{bmatrix} \quad (\text{χρησιμοποιώντας την (6)})\end{aligned}$$

επίσης τετριμμένο αποτέλεσμα.

Θα δείξουμε ότι

$$\begin{aligned}
 \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \mathbf{a}^{(0)} [\mathbf{w}^{(2)} [2(\mathbf{a}^{(2)} - \mathbf{y})]]^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_{784} \end{bmatrix} \begin{bmatrix} \begin{bmatrix} w_{1,1} & w_{1,2} & \dots & w_{1,10} \\ w_{2,1} & w_{2,2} & \dots & w_{2,10} \\ \vdots & \vdots & \ddots & \vdots \\ w_{10,1} & w_{10,2} & \dots & w_{10,10} \end{bmatrix} \begin{bmatrix} 2(a_1^{(2)} - y_1) \\ 2(a_2^{(2)} - y_2) \\ \vdots \\ 2(a_{10}^{(2)} - y_{10}) \end{bmatrix} \end{bmatrix}^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_{784} \end{bmatrix} \begin{bmatrix} w_{1,1} \cdot 2(a_1^{(2)} - y_1) + w_{1,2} \cdot 2(a_2^{(2)} - y_2) + \dots + w_{1,10} \cdot 2(a_{10}^{(2)} - y_{10}) \\ w_{2,1} \cdot 2(a_1^{(2)} - y_1) + w_{2,2} \cdot 2(a_2^{(2)} - y_2) + \dots + w_{2,10} \cdot 2(a_{10}^{(2)} - y_{10}) \\ \vdots \\ w_{10,1} \cdot 2(a_1^{(2)} - y_1) + w_{10,2} \cdot 2(a_2^{(2)} - y_2) + \dots + w_{10,10} \cdot 2(a_{10}^{(2)} - y_{10}) \end{bmatrix}^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_{784} \end{bmatrix} \begin{bmatrix} \sum_{j=1}^{10} w_{1,j} \cdot 2(a_j^{(2)} - y_j) \\ \sum_{j=1}^{10} w_{2,j} \cdot 2(a_j^{(2)} - y_j) \\ \vdots \\ \sum_{j=1}^{10} w_{10,j} \cdot 2(a_j^{(2)} - y_j) \end{bmatrix}^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_{784} \end{bmatrix} \begin{bmatrix} \sum_{j=1}^{10} w_{1,j} \cdot 2(a_j^{(2)} - y_j) & \dots & \sum_{j=1}^{10} w_{10,j} \cdot 2(a_j^{(2)} - y_j) \\ \vdots & \ddots & \vdots \\ \sum_{j=1}^{10} w_{1,j} \cdot 2(a_j^{(2)} - y_j) & \dots & \sum_{j=1}^{10} w_{10,j} \cdot 2(a_j^{(2)} - y_j) \end{bmatrix}^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} p_1 \sum_{j=1}^{10} w_{1,j} \cdot 2(a_j^{(2)} - y_j) & \dots & p_1 \sum_{j=1}^{10} w_{10,j} \cdot 2(a_j^{(2)} - y_j) \\ \vdots & \ddots & \vdots \\ p_{784} \sum_{j=1}^{10} w_{1,j} \cdot 2(a_j^{(2)} - y_j) & \dots & p_{784} \sum_{j=1}^{10} w_{10,j} \cdot 2(a_j^{(2)} - y_j) \end{bmatrix}^\top \\
 \Rightarrow \frac{\partial \mathcal{L}}{\partial w_i^{(2)}} &= \begin{bmatrix} \frac{\partial \mathcal{L}}{\partial w_{1,1}^{(2)}} & \frac{\partial \mathcal{L}}{\partial w_{1,2}^{(2)}} & \dots & \frac{\partial \mathcal{L}}{\partial w_{1,10}^{(2)}} \\ \frac{\partial \mathcal{L}}{\partial w_{2,1}^{(2)}} & \frac{\partial \mathcal{L}}{\partial w_{2,2}^{(2)}} & \dots & \frac{\partial \mathcal{L}}{\partial w_{2,10}^{(2)}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \mathcal{L}}{\partial w_{784,1}^{(2)}} & \frac{\partial \mathcal{L}}{\partial w_{784,2}^{(2)}} & \dots & \frac{\partial \mathcal{L}}{\partial w_{784,10}^{(2)}} \end{bmatrix} \quad (\text{χρησιμοποιώντας την (8)})
 \end{aligned}$$

## Gradient Descent

Όπως αναφέραμε και στο Back propagation, στόχος μας είναι να βρούμε το ολικό ελάχιστο της συνάρτησης κόστους  $\mathcal{L}$  και άρα να κινηθούμε στην κατεύθυνση του  $\vec{\nabla} f$ . Γράφω κάτι όχι συγκεκριμένο και καινούριο

$$\sum_{\min}^{\max} \mathcal{X}$$